

Tratamento da Base 1 – 1. PROD__20260824

A primeira etapa do projeto consistiu no tratamento e na preparação da **Base 1 – 1. PROD__20260824**, utilizada como uma das fontes de dados para o desenvolvimento das análises. O tratamento foi realizado utilizando a linguagem Python, por meio do ambiente Google Colab, com o auxílio das bibliotecas Pandas e NumPy.

A base **1. PROD__20260824** foi disponibilizada originalmente em formato Excel e importada para o ambiente de análise, sendo armazenada em um DataFrame denominado `df`. O objetivo dessa etapa foi avaliar a estrutura e a qualidade dos dados, identificar inconsistências e informações desnecessárias e preparar a base para as etapas posteriores do projeto.

1.1 Análise inicial da base

Inicialmente, foi realizada uma inspeção da estrutura da **Base 1 – 1. PROD__20260824**, buscando identificar a quantidade de registros, o número de colunas, os nomes dos campos e os tipos de dados presentes.

A base original apresentava **56.832 registros e 136 colunas**, contendo informações relacionadas aos produtos cadastrados, incluindo códigos, nomes, características, classificações, informações fiscais, parâmetros de produção e outros atributos.

Essa análise inicial foi importante para compreender a dimensão da base antes da realização de qualquer alteração, permitindo que as modificações realizadas posteriormente fossem acompanhadas e justificadas.

1.2 Análise de valores ausentes

Após a avaliação inicial, foi realizada uma análise dos valores ausentes existentes na **Base 1 – 1. PROD__20260824**.

Para cada coluna, foram calculadas a quantidade de valores vazios e sua respectiva representatividade percentual em relação ao total de registros. Essa análise permitiu identificar campos com diferentes níveis de preenchimento e separar aqueles que apresentavam ausência significativa de informações daqueles que possuíam apenas poucos registros vazios.

As colunas com elevado percentual de valores ausentes foram inicialmente classificadas como candidatas à avaliação, mas não foram removidas automaticamente. Dessa forma, buscou-se evitar a exclusão de informações que pudessem apresentar alguma relevância para as análises posteriores.

1.3 Identificação e remoção de colunas totalmente vazias

A partir da análise dos valores ausentes, foram identificadas as colunas que não apresentavam nenhum valor preenchido em toda a **Base 1 – 1. PROD__20260824**.

Foram removidas **24 colunas totalmente vazias**, entre elas:

- Unidade de Medida Própria;
- Unidade de Negócio;
- Faixa Horário Manhã Inicial;
- Faixa Horário Manhã Final;
- Faixa Horário Tarde Inicial;
- Faixa Horário Tarde Final;
- Faixa Horário Noite Inicial;
- Faixa Horário Noite Final;
- Número (IPTU/INCRA);
- Data Instalação da Estrutura;
- Hora Inicial Exibição;
- Hora Final Exibição;
- Código MS;
- Produtos Associados para Venda;
- Vazão L/HA;
- Temperatura;
- % U. R. Ar;
- Classe Toxicológica;
- Quantidade HA;
- Formulação;
- Veiculante;
- Tipo de Produto Aplicado;
- Velocidade do Vento;
- Data Lev ICMS ST.

Como resultado dessa etapa, a base passou de **136 para 112 colunas**, mantendo os **56.832 registros**.

A remoção foi realizada somente após a confirmação de que as colunas estavam integralmente vazias, garantindo que não fossem eliminados dados preenchidos.

1.4 Verificação de colunas visualmente vazias

Durante a inspeção da planilha, também foram identificadas algumas colunas que aparentavam estar vazias visualmente, apesar de a análise inicial indicar a existência de células não classificadas simplesmente como NaN.

Para garantir uma avaliação mais precisa, foi realizada uma verificação considerando também células que poderiam conter espaços ou outros caracteres sem conteúdo efetivo.

A análise confirmou que as seguintes 12 colunas estavam efetivamente vazias em todos os registros:

- Programa de Desconto;
- PGC;
- Marca;
- Grupo do Produto;
- Subgrupo do Produto;
- Fórmula do Produto;
- Produto Venda;

- Unidade de Medida Venda;
- Tipo do Assinante;
- Grupo de Tensão;
- Código de Consumo;
- Mensagem.

Essas colunas foram então removidas da **Base 1 – 1. PROD__20260824**.

Por outro lado, as colunas **Quantidade Inserção Hora** e **Total Inserção Dia** apresentaram informações preenchidas em parte dos registros e, por esse motivo, foram mantidas. Essa verificação evitou que colunas fossem removidas apenas com base na aparência visual da planilha.

Após essa etapa, a base passou a apresentar **100 colunas**.

1.5 Verificação de registros duplicados

Também foi realizada uma análise para verificar a existência de registros completamente duplicados na **Base 1 – 1. PROD__20260824**.

O resultado apresentou **0 registros duplicados**, indicando que não foram encontradas linhas integralmente repetidas. Dessa forma, não foi necessária a exclusão de registros por duplicidade nessa etapa do tratamento.

1.6 Análise da quantidade de valores distintos

Após as primeiras etapas de limpeza, foi realizada uma análise da quantidade de valores distintos existentes em cada coluna.

Essa análise teve como objetivo identificar campos que apresentavam o mesmo valor em todos os registros ou que possuíam baixa variabilidade. A quantidade de valores distintos foi utilizada como critério de investigação, e não como motivo automático para exclusão.

Essa etapa é importante porque uma coluna possuir poucos valores diferentes não significa necessariamente que ela seja desnecessária. Campos com dois ou três valores, por exemplo, podem representar classificações ou indicadores importantes para as análises.

Por esse motivo, as colunas identificadas como constantes ou com baixa quantidade de valores distintos foram tratadas como pontos de avaliação, preservando-se os dados até que sua relevância pudesse ser confirmada.

1.7 Identificação e remoção da linha de resumo

Durante a análise da estrutura da **Base 1 – 1. PROD__20260824**, foi identificada uma inconsistência no final da planilha.

A última linha não correspondia a um produto ou registro efetivo da base. Na coluna **Alternativo**, essa linha apresentava o texto "**Quantidade - 56831**", enquanto as demais colunas estavam vazias.

A partir dessa característica, a linha foi identificada como um **registro de resumo/rodapé gerado na exportação da planilha**, e não como parte dos dados de produtos.

Essa linha foi removida antes da continuidade das análises, evitando que o registro de resumo interferisse nos cálculos de quantidade de valores distintos, valores ausentes e demais análises realizadas sobre os registros.

Após sua remoção, a **Base 1 – 1. PROD__20260824** passou a apresentar **56.831 registros efetivos**.

1.8 Resultado do tratamento da Base 1

Ao final da primeira etapa de tratamento, a **Base 1 – 1. PROD__20260824** passou por um processo de limpeza estruturado, no qual as exclusões foram realizadas somente após a identificação e validação das informações.

O resultado das principais etapas pode ser observado a seguir:

Etapas	Registros Colunas	
Base 1 original – 1. PROD__20260824	56.832	136
Após remoção das colunas totalmente vazias	56.832	112
Após remoção das colunas adicionais identificadas como efetivamente vazias	56.832	100
Após remoção da linha de resumo	56.831	100

Dessa forma, o tratamento da **Base 1 – 1. PROD__20260824** teve como finalidade principal preparar os dados para as próximas etapas do projeto, reduzindo informações sem conteúdo e eliminando um registro de resumo que não fazia parte da base efetiva.

O processo também permitiu realizar uma avaliação inicial da qualidade dos dados, verificando valores ausentes, duplicidades, quantidade de valores distintos e possíveis inconsistências estruturais.

A metodologia adotada priorizou a **validação antes da exclusão**, garantindo que as alterações realizadas na base fossem justificadas por evidências encontradas nos próprios dados. Com isso, a base tratada foi preparada para dar continuidade às etapas seguintes do projeto, mantendo os registros e campos que apresentavam informações potencialmente relevantes para as análises.